Data Understanding & Data Preprocessing – House Price Dataset

Import Library

Mengimpor library yang digunakan untuk analisis data, visualisasi, dan preprocessing seperti Pandas, NumPy, Matplotlib, dan Scikit-learn.

```
# Import library
import numpy as np
import os
import matplotlib as mpl
import matplotlib.pyplot as plt
import pandas as pd
```

Load Dataset

Dataset House Price dimuat dari file CSV dan menampilkan 5 data

```
# Load Dataset
df = pd.read_csv('/content/drive/MyDrive/MAGANG/minggu 2_proyek 1/House Price Prediction Dataset.csv')

df.head()
```

	Id	Area	Bedrooms	Bathrooms	Floors	YearBuilt	Location	Condition	Garage	Price
0	1	1360	5	4	3	1970	Downtown	Excellent	No	149919
1	2	4272	5	4	3	1958	Downtown	Excellent	No	424998
2	3	3592	2	2	3	1938	Downtown	Good	No	266746
3	4	966	4	2	2	1902	Suburban	Fair	Yes	244020
4	5	4926	1	4	2	1975	Downtown	Fair	Yes	636056

Dataset Overview

Dataset terdiri dari 2000 data dan 10 variabel. Terdapat 7 fitur numerik dan 3 fitur kategorikal. Variabel Price digunakan sebagai target untuk prediksi harga rumah

```
df.shape
df.columns
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 10 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   Id         2000 non-null   int64
 1   Area       2000 non-null   int64
 2   Bedrooms   2000 non-null   int64
 3   Bathrooms  2000 non-null   int64
 4   Floors     2000 non-null   int64
 5   YearBuilt  2000 non-null   int64
 6   Location   2000 non-null   object
 7   Condition  2000 non-null   object
 8   Garage     2000 non-null   object
 9   Price      2000 non-null   int64
dtypes: int64(7), object(3)
memory usage: 156.4+ KB
```

Dataset Audit

- Rata-rata luas rumah sekitar 2786 sqft
- Rata-rata jumlah kamar tidur sekitar 3 kamar
- Rata-rata kamar mandi sekitar 2–3 kamar mandi
- Harga rumah memiliki rentang sekitar 50.000 hingga hampir 1.000.000 Hal ini menunjukkan bahwa dataset memiliki variasi karakteristik rumah yang cukup beragam.

```
df.describe()
```

	Id	Area	Bedrooms	Bathrooms	Floors	YearBuilt	Price
count	2000.000000	2000.000000	2000.000000	2000.00000	2000.000000	2000.000000	2000.000000
mean	1000.500000	2786.209500	3.003500	2.55250	1.993500	1961.446000	537676.855000
std	577.494589	1295.146799	1.424606	1.10899	0.809188	35.926695	276428.845719
min	1.000000	501.000000	1.000000	1.00000	1.000000	1900.000000	50005.000000
25%	500.750000	1653.000000	2.000000	2.00000	1.000000	1930.000000	300098.000000
50%	1000.500000	2833.000000	3.000000	3.00000	2.000000	1961.000000	539254.000000
75%	1500.250000	3887.500000	4.000000	4.00000	3.000000	1993.000000	780086.000000
max	2000.000000	4999.000000	5.000000	4.00000	3.000000	2023.000000	999656.000000

Missing Value Analysis

Seluruh variabel memiliki nilai 0 sehingga dataset tidak memiliki data kosong

```
df.isnull().sum()
```

	0
Id	0
Area	0
Bedrooms	0
Bathrooms	0
Floors	0
YearBuilt	0
Location	0
Condition	0
Garage	0
Price	0

dtype: int64

Distribusi Target

Histogram menunjukkan bahwa harga rumah berada pada kisaran 50.000 hingga sekitar 1.000.000.

```
plt.hist(df['Price'], bins=30)
plt.title("Distribusi Harga Rumah")
plt.xlabel("Price")
plt.ylabel("Frequency")
plt.show()
```

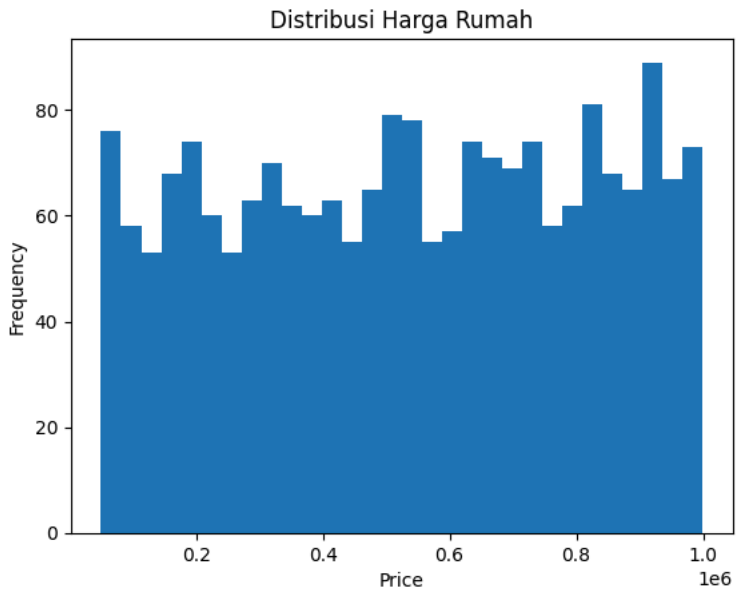

Data Cleaning

Data cleaning dilakukan dengan menghapus kemungkinan data duplikat dan memastikan tidak terdapat data kosong pada dataset.

```
df.drop_duplicates(inplace=True)
df.dropna(inplace=True)
```

Encoding

Variabel kategorikal seperti Location, Condition, dan Garage diubah menjadi bentuk numerik menggunakan LabelEncoder agar dapat diproses oleh model machine learning.

```
from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()

df['Location'] = le.fit_transform(df['Location'])
df['Condition'] = le.fit_transform(df['Condition'])
df['Garage'] = le.fit_transform(df['Garage'])
```

Split Data

Dataset dibagi menjadi data training (80%) dan data testing (20%) untuk proses pelatihan dan evaluasi model.

```
from sklearn.model_selection import train_test_split

X = df.drop('Price', axis=1)
y = df['Price']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

Scaling

Feature scaling dilakukan menggunakan StandardScaler untuk menormalkan nilai fitur. Scaling dilakukan setelah proses split data untuk menghindari data leakage.

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```